*UNIVERSITÀ DEGLI STUDI DI TORINO*

# Progetto di Sistemi Informativi

## Laboratorio · Anno accademico 2024/2025

## Data warehouse, analisi delle vendite e segmentazione dei clienti

**Federico Santorsola**
**Davide Vercelli**

| PROGETTAZIONE | ANALISI | DATA MINING |
|---|---|---|
| Etichetta discografica<br>UML, BPMN, DFM e schema dimensionale | Northwind<br>PostgreSQL, ricavi e medie mobili trimestrali | Clienti<br>KNIME, normalizzazione e clustering k-means |

*Relazione del progetto*

*01 / SISTEMI INFORMATIVI*

# Obiettivi e architettura

Il progetto affronta l'intero percorso dall'analisi di un dominio applicativo alla lettura analitica dei dati. La prima parte riguarda la progettazione di una data warehouse per un'etichetta discografica; la seconda e la terza utilizzano il dominio Northwind per analizzare le vendite e individuare gruppi di clienti con comportamenti simili.

| Parte | Obiettivo | Artefatti |
|---|---|---|
| 1. Progettazione | Modellare il dominio discografico e le sue esigenze analitiche. | Modello UML, processo BPMN, DFM e schema dimensionale. |
| 2. Analisi delle vendite | Individuare i prodotti con i ricavi maggiori e descrivere l'andamento trimestrale. | Query PostgreSQL, workflow KNIME e tabelle esportabili. |
| 3. Data mining | Segmentare i clienti secondo due insiemi di caratteristiche. | Feature aggregate, normalizzazione, k-means e grafici dei cluster. |

## Flusso dei dati

PostgreSQL esegue le join, le aggregazioni e le funzioni finestra. KNIME legge i risultati delle query e realizza l'analisi visuale, la normalizzazione e il clustering. Una pipeline Python permette di eseguire le stesse analisi SQL da terminale ed esportare risultati e grafici.

Le query presenti nella cartella **sql/** costituiscono il riferimento condiviso: lo script di confezionamento le sincronizza con i DB Table Selector del workflow. Il progetto può quindi essere esplorato attraverso l'interfaccia KNIME oppure da riga di comando.

## Dati e riproducibilità

La repository contiene un dataset dimostrativo sintetico con lo schema minimo necessario alle analisi. Il backup Northwind distribuito dal corso non è incluso. Tutti i risultati numerici riportati nella sezione dimostrativa si riferiscono esclusivamente ai dati sintetici.

*02 / SISTEMI INFORMATIVI*

# Modello di dominio

L'etichetta discografica pubblica dischi e stipula contratti con le band. Le band riuniscono artisti e sono collegate ai manager; le sessioni di registrazione descrivono la produzione dei dischi. Promoter e negozi appartengono alla rete commerciale, mentre gli ordini collegano il negozio al disco richiesto.

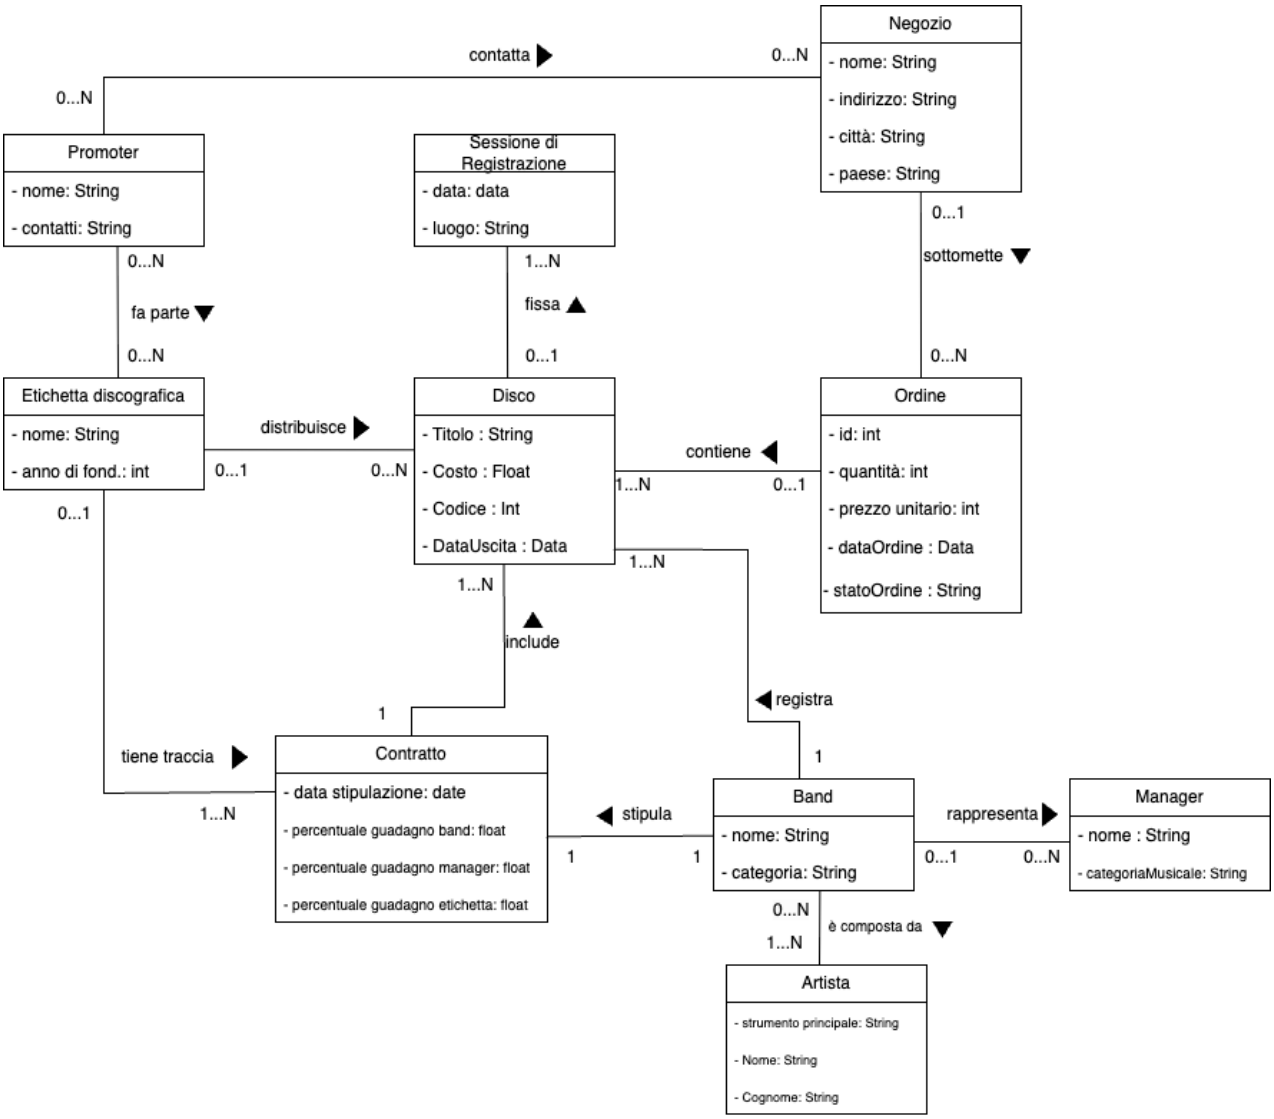



*Figura 1. Modello UML del dominio discografico.*

Le entità commerciali e produttive costituiscono il contesto dell'analisi. Per le interrogazioni OLAP assumono particolare rilievo il disco, la band, l'artista, il contratto, il negozio e il tempo. Informazioni operative come i contatti o i dettagli delle sessioni non sono necessarie a ogni aggregazione analitica.

*03 / SISTEMI INFORMATIVI*

# Processo di acquisto e dati operativi

Il processo BPMN descrive l'interazione fra negozio ed etichetta, dalla richiesta del disco alle attività di gestione dell'ordine. Le attività dei due partecipanti sono collocate in corsie distinte, con i punti di decisione e gli scambi informativi necessari al processo.

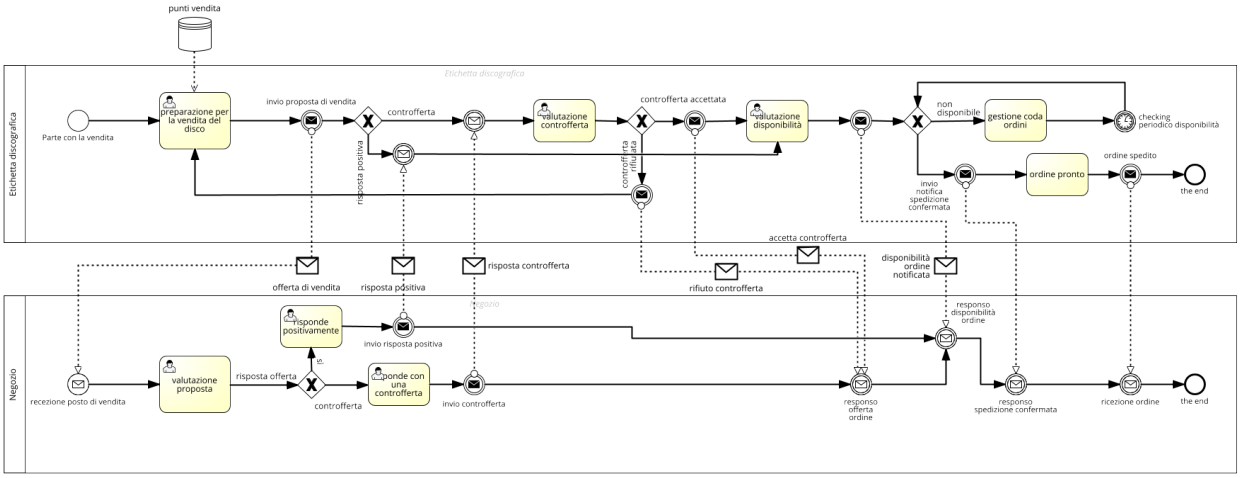



*Figura 2. Processo di acquisto di un disco da parte del negozio.*

## Struttura relazionale del dominio

| Entità | Informazioni principali |
|---|---|
| Etichetta, disco | Identità dell'etichetta; codice, titolo, costo e data di uscita del disco. |
| Contratto | Data di stipulazione, soggetti coinvolti e quote di ripartizione. |
| Band, artista, manager | Identità, categoria musicale, strumento e appartenenza al gruppo. |
| Registrazione, promoter | Sessione, data e luogo; soggetti della promozione. |
| Negozio, ordine | Punto vendita, città e paese; disco, quantità, prezzo, data e stato dell'ordine. |

La base operativa supporta il processo commerciale. La vista dimensionale seleziona invece gli attributi utili alle analisi, mantenendo esplicita la granularità dell'evento osservato.

*04 / SISTEMI INFORMATIVI*

# Progettazione dimensionale

Il fatto centrale è la riga d'ordine di un disco destinata a un negozio in una determinata data. Ordini distinti devono restare identificabili anche quando condividono disco, negozio e giorno. Quantità e prezzo permettono di calcolare il ricavo; lo stato dell'ordine serve a distinguere richieste soddisfatte e non soddisfatte.

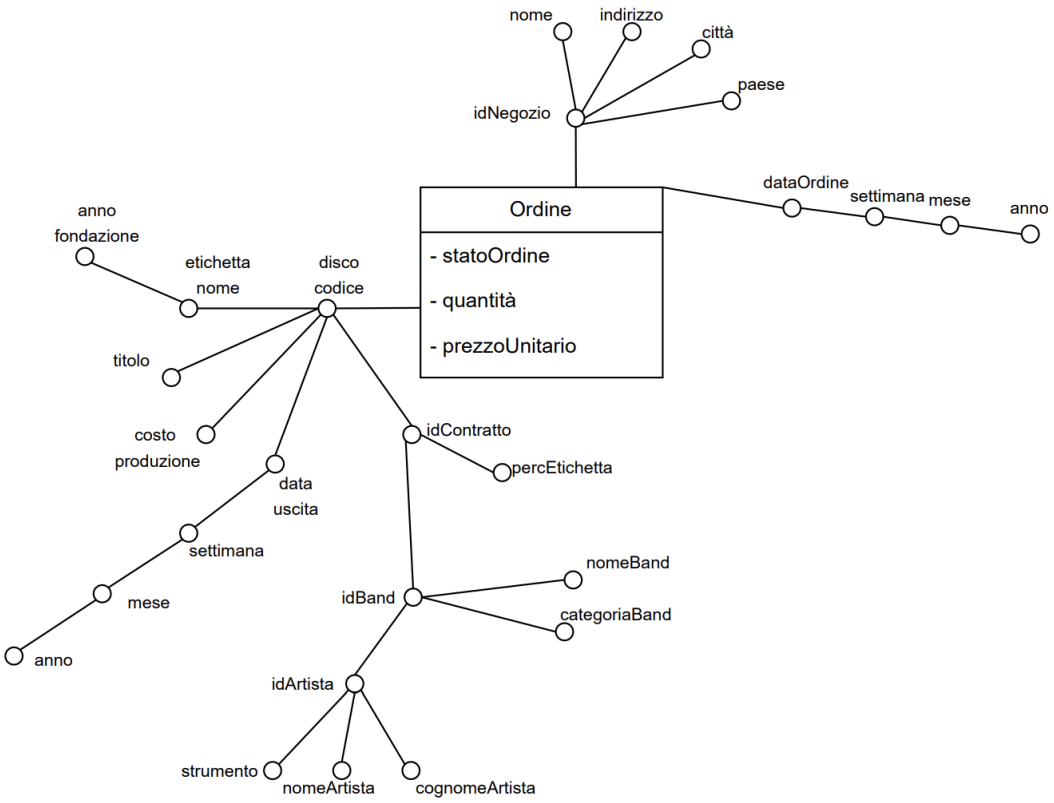



*Figura 3. Organizzazione dimensionale degli attributi intorno al fatto Ordine.*

| Asse di analisi | Gerarchie e attributi |
|---|---|
| Tempo | Data, mese, anno e settimana secondo una convenzione esplicita. |
| Territorio | Negozio, città e paese. |
| Prodotto e contratto | Disco, etichetta, contratto e band. |
| Artista | Identità dell'artista e appartenenza alla band. |

Lo stato è un attributo categorico e il prezzo unitario non si somma direttamente. Il conteggio delle richieste e la somma delle unità richieste rispondono a domande diverse. Le misure derivate devono specificare i rispettivi criteri di calcolo.

*05 / SISTEMI INFORMATIVI*

# Schema e interrogazioni della DW

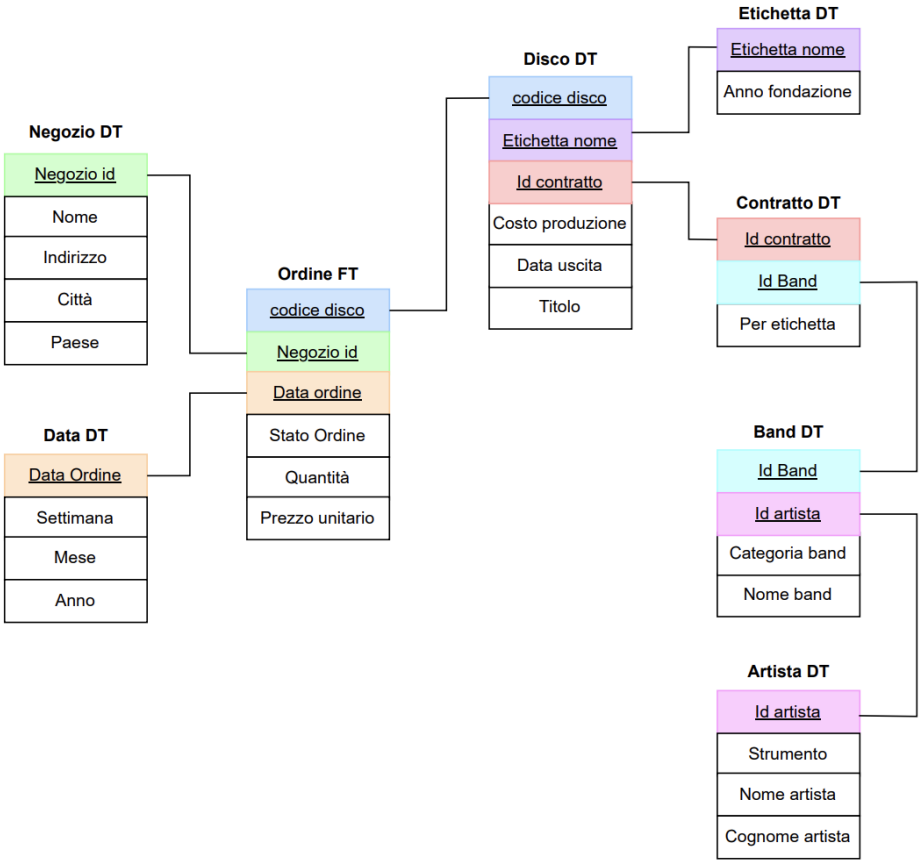



*Figura 4. Schema dimensionale con dimensioni collegate al fatto e fra loro.*

Le interrogazioni riguardano i dischi, i gruppi e gli artisti con i risultati economici maggiori o minori per periodo, le richieste non soddisfatte per territorio e il numero di richieste per prodotto o interprete.

La separazione fra dimensioni collegate realizza un'organizzazione a fiocco di neve. In un'implementazione fisica, l'appartenenza di più artisti alla stessa band richiede una relazione ponte e una regola di attribuzione per evitare di moltiplicare i ricavi nelle join.

Guadagno e rendimento dell'investimento richiedono inoltre regole contabili esplicite: stati che riconoscono il ricavo, validità temporale del contratto, quote dell'etichetta, perimetro dell'investimento e allocazione dei costi di produzione. Il costo complessivo di un disco non deve essere ripetuto integralmente su ogni ordine.

Questa parte del progetto è una progettazione concettuale e logica. Le componenti eseguibili della repository si riferiscono alle analisi Northwind.

*06 / SISTEMI INFORMATIVI*

# Analisi delle vendite Northwind

## Prodotti con il ricavo maggiore

La prima interrogazione seleziona i cinque prodotti con il ricavo lordo più elevato. Il prezzo proviene dalla riga d'ordine, così da rispettare le variazioni storiche e non sostituirlo con il prezzo corrente del catalogo.

```
ricavo riga = prezzo storico × quantità
ricavo prodotto = somma dei ricavi delle righe
```

Il raggruppamento comprende l'identificativo del prodotto e il nome. Due prodotti omonimi rimangono così distinti. Il risultato è ordinato per ricavo decrescente e, a parità di ricavo, per identificativo. Gli sconti sono esclusi da questa specifica metrica, che misura ricavi e non profitti contabili.

## Media mobile su tre trimestri

La seconda interrogazione calcola le quantità vendute per trimestre e applica una finestra sul trimestre corrente e sui due precedenti. Sono disponibili due varianti: per prodotto e per coppia prodotto-paese di spedizione.

| Passaggio | Operazione |
|---|---|
| 1. Aggregazione | Somma delle quantità per prodotto, trimestre ed eventualmente ShipCountry. |
| 2. Calendario | Inserimento a zero dei trimestri interni senza vendite, dal primo all'ultimo osservato di ciascuna serie. |
| 3. Finestra | AVG con PARTITION BY sulla serie e ROWS BETWEEN 2 PRECEDING AND CURRENT ROW. |
| 4. Inizio della serie | Nei primi due trimestri si usano le osservazioni disponibili, senza inventare periodi precedenti. |

Le righe prive di data non partecipano alle analisi trimestrali. La variante territoriale esclude anche i paesi sconosciuti. Ogni serie è indipendente dalle altre e l'ordinamento cronologico attraversa correttamente il cambio di anno.

*07 / SISTEMI INFORMATIVI*

# Segmentazione dei clienti

Le righe d’ordine sono aggregate per cliente. Il numero di ordini conta gli identificativi distinti, evitando che un ordine con più prodotti venga contato più volte. La spesa netta tiene conto degli sconti applicati a ogni singola riga.

| Modello | Caratteristiche |
| --- | --- |
| Comportamento di acquisto | Numero di ordini distinti, numero di prodotti distinti, spesa lorda totale. |
| Quantità e sconti | Numero di ordini distinti, quantità totale, spesa netta totale, sconto medio per riga. |

```
spesa netta = somma(prezzo storico × quantità × (1 − sconto))
```

Lo sconto medio è una media delle righe, senza ponderazione per quantità o valore. Gli sconti mancanti sono trattati come zero. I clienti senza acquisti sono esclusi dal clustering.

## Normalizzazione e k-means

Ogni caratteristica è normalizzata nell’intervallo [0, 1] con trasformazione min-max. Se una caratteristica è costante, il suo valore normalizzato è zero. Entrambi i modelli utilizzano tre cluster e distanza euclidea.

La pipeline Python impiega seed 0, dieci inizializzazioni e al massimo 99 iterazioni per inizializzazione. Viene selezionata la soluzione con la minore somma delle distanze quadratiche interne ai cluster. KNIME utilizza il proprio nodo k-Means con seed 0 e un limite di 99 iterazioni.

I risultati comprendono dimensioni dei cluster, centroidi normalizzati e nelle unità originali, intervalli delle caratteristiche e inerzia. Gli identificativi dei cluster sono etichette arbitrarie; i grafici sono proiezioni su due caratteristiche. Non viene assegnato automaticamente un significato commerciale ai gruppi.

La presenza di outlier e la scelta di k richiedono interpretazione. Il progetto conserva le osservazioni e rende espliciti i parametri utilizzati, senza sostenere che tre cluster siano ottimali per ogni dataset.

*08 / SISTEMI INFORMATIVI*

# Workflow ed esecuzione

Il workflow KNIME contiene 29 nodi distribuiti in quattro rami: prodotti con maggior ricavo, analisi trimestrale con due uscite, segmentazione degli acquisti e segmentazione basata su quantità e sconti.

| Componente | Ruolo |
|---|---|
| PostgreSQL Connector | Connessione locale al database; credenziali da configurare nell'ambiente di esecuzione. |
| DB Table Selector / Reader | Esecuzione delle query e lettura dei risultati in KNIME. |
| Normalizer / k-Means | Normalizzazione delle caratteristiche e assegnazione ai cluster. |
| Denormalizer / Scatter Plot | Ispezione dei risultati nelle unità originali e nello spazio normalizzato. |
| Data to Report (BIRT) | Collegamento delle tabelle al report designer; le tabelle sono consultabili anche direttamente. |

## Esecuzione dimostrativa da terminale

```
createdb si_demo
psql -X --set=ON_ERROR_STOP=1 --single-transaction
  --dbname=si_demo --file=sql/demo_data.sql
python3 scripts/analyze.py --database si_demo
```

Il comando psql è mostrato su due righe per ragioni di impaginazione e va eseguito su un'unica riga. La connessione utilizza le impostazioni standard di PostgreSQL. I risultati vengono scritti nella cartella results/.

La pipeline richiede Python 3.10 o successivo e il client PostgreSQL, senza dipendenze Python esterne. Esporta sei file CSV, due grafici SVG e un riepilogo JSON. Le quattro query sono eseguite in un'unica transazione in sola lettura con isolamento repeatable read.

I test automatici verificano le formule analitiche, le finestre temporali, il clustering e le esportazioni. I controlli sul workflow verificano XML, collegamenti, assenza di credenziali salvate e corrispondenza fra sorgenti e archivio KNIME.

*09 / SISTEMI INFORMATIVI*

# Risultati dimostrativi e verifica

Il dataset sintetico comprende 7 clienti, 6 prodotti, 9 ordini e 13 righe d'ordine. Sei clienti hanno acquisti. I risultati seguenti descrivono esclusivamente questo esempio e non il backup Northwind del corso.

| ID prodotto | Nome | Ricavo lordo |
|---|---|---|
| 1 | Demo Tea | 1200 |
| 5 | Demo Juice | 520 |
| 3 | Demo Coffee | 320 |
| 2 | Demo Tea | 106 |
| 4 | Demo Cocoa | 24 |

| Trimestre, prodotto 1 | Quantità | Media mobile |
|---|---|---|
| 2024 Q1 | 10 | 10,00 |
| 2024 Q2 | 20 | 15,00 |
| 2024 Q3 | 30 | 20,00 |
| 2024 Q4 | 0 | 16,67 |
| 2025 Q1 | 40 | 23,33 |

I prodotti omonimi restano distinti; il trimestre senza vendite contribuisce alla media e la finestra prosegue correttamente nel nuovo anno. Il cliente A ha due ordini distinti, tre prodotti distinti, spesa lorda 520, spesa netta 474 e quantità complessiva 46.




*Figura 5. Proiezioni dei due modelli sul dataset sintetico; dimensioni dei cluster [3, 1, 2] e [3, 2, 1].*

Le verifiche analitiche e i sei test Python sono stati eseguiti sui dati dimostrativi. GitHub Actions configura inoltre un servizio PostgreSQL 17 per i controlli SQL. L'importazione e l'esecuzione interattiva in KNIME richiedono la verifica delle estensioni e della connessione nell'installazione locale.